

Étude intermédiaire: choix des variables, élagage du dataframe et ébauche de plan

Groupe 1

Après le 1er entretien oral, nous avons appris plusieurs choses :

- Premièrement, nous expliquerons plus en profondeur le lien entre les différentes variables, mais également le type de variables utilisées (intérêt, contrôle, transitif).
- Nous essayons d'améliorer la clarté des graphiques afin de transmettre au mieux un message ou une analyse spécifique plutôt que de juste représenter le lien entre deux variables ou plus.

Après la première étude exploratoire faite dans `etude_exploratoire_clean.qmd`, nous nous appliquons ici à effectuer tous les traitements de base du dataframe afin d'en sélectionner une partie pertinente à notre étude de l'impact des technologies sur les performances éducatives.

Une fois cela fait, nous nous pencherons sur une ébauche de plan relatif à notre étude.

Partie I: Nettoyage de la base de données

1. Librairies et téléchargement de la base.

```
library(tidyverse)
```

Téléchargement de la base `./stu_qqq.rds` :

```
responses_raw <- readRDS('./stu_qqq.rds')
```

2. Elagage et modification du nom des variables

On garde une multitude de variables que l'on renomme :

- Variables de contrôle (age, sexe, position socio-économique et géographique, ressources disponibles) :
 - CNT : country
 - ST003D03T : birth_year
 - ST004D01T : genre
 - PAREDINT : index_highest_parental_education
 - HISEI : index_highest_parental_occupation_status
 - ESCS : index_socioeconomic_status
 - ST250Q02JA : computer_for_work_available
 - ST250Q03JA : educational_apps_available
 - ST250Q05JA : internet_access_available
 - ADMINMODE : response_medium (biais qu'il peut y avoir sur le plan socio-économique lorsque quelqu'un utilise du papier plutôt qu'un ordinateur pour répondre, et ses prédispositions à utiliser ou non un ordinateur)
 - ST256Q10JA : book_reading_for_school (biais qu'il peut y avoir pour quelqu'un utilisant plusieurs méthodes d'apprentissage)
 - STRATUM : region_and_schools (pour une étude de cas sur la France, en comparant les résultats obtenus pour un Lycée GT et un Lycée Pro par ex.).
- Variables d'intérêt (technologies et leurs utilisations, performances éducatives) :
 - Technologies :
 - * ST326Q01JA : digital_resources_usage_for_learning_at_school_by_day
 - * ST326Q02JA : digital_resources_usage_for_learning_outside_school_by_day
 - * ST326Q03JA : digital_resources_usage_for_learning_on_weekends
 - * ST326Q04JA : digital_resources_usage_for_leisure_at_school_by_day
 - * ST326Q05JA : digital_resources_usage_for_leisure_outside_school_by_day
 - * ST326Q06JA : digital_resources_usage_for_leisure_on_weekends
 - * ST253Q01JA : nb_digital_devices_at_home
 - * IC174Q10JA : digital_games_usage_for_learning

– Performances éducatives :

- * REPEAT : repeated_a_year
- * PV1MATH : pv_math
- * PV1READ : pv_reading_comprehension
- * PV1SCIE : pv_science

Faisons alors un élagage du dataframe avec ces nouvelles variables :

```
responses <- responses_raw |>
  select(
    country = CNT,
    birth_year = ST003D03T,
    genre = ST004D01T,
    index_highest_parental_education = PAREDINT,
    index_highest_parental_occupation_status = HISEI,
    index_socioeconomic_status = ESCS,
    computer_for_work_available = ST250Q02JA,
    educational_apps_available = ST250Q03JA,
    internet_access_available = ST250Q05JA,
    response_medium = ADMINMODE,
    book_reading_for_school = ST256Q10JA,
    region_and_schools = STRATUM,

    digital_resources_usage_for_learning_at_school_by_day = ST326Q01JA,
    digital_resources_usage_for_learning_outside_school_by_day = ST326Q02JA,
    digital_resources_usage_for_learning_on_weekends = ST326Q03JA,
    digital_resources_usage_for_leisure_at_school_by_day = ST326Q04JA,
    digital_resources_usage_for_leisure_outside_school_by_day = ST326Q05JA,
    digital_resources_usage_for_leisure_on_weekends = ST326Q06JA,
    nb_digital_devices_at_home = ST253Q01JA,
    digital_games_usage_for_learning = IC174Q10JA,

    repeated_a_year = REPEAT,
    pv_math = PV1MATH,
    pv_reading_comprehension = PV1READ,
    pv_science = PV1SCIE
  )
```

Partie II: Ebauche de plan

Introduction

Présentation du sujet : L'objectif de cette étude est d'analyser la relation complexe entre l'accès aux technologies numériques et la performance scolaire des élèves (étude PISA 2022). Nous chercherons à dépasser la simple analyse de corrélation pour identifier d'éventuels effets de seuil et l'influence des types d'usage.

Partie Préliminaire : État des lieux de la fracture numérique

Objectif : Avant de lier technologie et performance, il est nécessaire de comprendre comment l'accès aux outils est distribué.

A. Disparités d'équipement et d'accès

Analyse descriptive de la disponibilité des outils numériques (ordinateurs, tablettes, internet) au domicile des élèves. Comparaison entre les pays ou les zones géographiques.

B. Le poids des déterminants socio-économiques

Étude de l'influence de l'indice de statut économique, social et culturel (ESCS) et de la localisation sur l'utilisation et l'accès à ces équipements. La fracture numérique est-elle résorbée ou persiste-t-elle sous de nouvelles formes ?

Partie 1 : L'ambivalence du lien entre numérique et réussite

Objectif : Tester l'hypothèse commune selon laquelle l'accès au numérique favorise la réussite.

A. L'apport potentiel : Corrélation globale et densité d'usage

Analyse bivariable entre le temps passé sur les écrans et les résultats scolaires. Observe-t-on une corrélation positive, négative ou nulle sur l'ensemble de la population ?

B. Les facteurs modérateurs de la performance

L'impact du numérique n'est pas uniforme. Cette sous-partie examine comment la relation change selon :

1. L'âge et le niveau scolaire.
2. La nature de l'usage (usage pédagogique, usage récréatif).

Partie 2 : Au-delà de la linéarité : La recherche d'un "dosage" optimal

Objectif : Affiner le modèle en recherchant des effets non-linéaires (effet de seuil).

A. Méthodologie : Construction d'un indicateur multidimensionnel

Justification et création d'un score de performance global (synthèse des scores Mathématiques, Lecture et Sciences) pour obtenir une mesure robuste de la réussite scolaire.

B. L'existence d'un seuil au delà duquel les technologies sont contre-productives

Analyse graphique et statistique pour vérifier l'existence d'un seuil de saturation : à partir de quel volume d'heures l'utilisation des outils numériques devient-elle contre-productive ? Mise en évidence des tendances conditionnelles (par niveau scolaire).

Conclusion

Synthèse des résultats : confirmation ou infirmation de l'effet de seuil. Recommandations sur l'usage raisonné du numérique basées sur les données analysées.