

Étude intermédiaire: choix des variables, élagage du dataframe et ébauche de plan

Groupe 1

Après le 1er entretien oral, nous avons appris plusieurs choses :

- Premièrement, nous expliquerons plus en profondeur le lien entre les différentes variables, mais également le type de variables utilisées (intérêt, contrôle, transitif).
- Nous essayons d'améliorer la clarté des graphiques afin de transmettre au mieux un message ou une analyse spécifique plutôt que de juste représenter le lien entre deux variables ou plus.

Après la première étude exploratoire faite dans `etude_exploratoire_clean.qmd`, nous nous appliquons ici à effectuer tous les traitements de base du dataframe afin d'en sélectionner une partie pertinente à notre étude de l'impact des technologies sur les performances éducatives.

Une fois cela fait, nous nous pencherons sur une ébauche de plan relatif à notre étude.

Partie I: Nettoyage de la base de données

1. Librairies et téléchargement de la base.

```
library(tidyverse)
```

Téléchargement de la base `./stu_qqq.rds` :

```
responses_raw <- readRDS('./stu_qqq.rds')
```

2. Elagage et modification du nom des variables

On garde une multitude de variables que l'on renomme :

- Variables de contrôle (age, sexe, position socio-économique et géographique, ressources disponibles) :
 - CNT : country
 - ST003D03T : birth_year
 - ST004D01T : genre
 - PAREDINT : index_highest_parental_education
 - HISEI : index_highest_parental_occupation_status
 - ESCS : index_socioeconomic_status
 - ST250Q02JA : computer_for_work_available
 - ST250Q03JA : educational_apps_available
 - ST250Q05JA : internet_access_available
 - ADMINMODE : response_medium (biais qu'il peut y avoir sur le plan socio-économique lorsque quelqu'un utilise du papier plutôt qu'un ordinateur pour répondre, et ses prédispositions à utiliser ou un ordinateur)
 - ST256Q10JA : book_reading_for_school (biais qu'il peut y avoir pour quelqu'un utilisant plusieurs méthodes d'apprentissage)
 - STRATUM : region_and_schools (pour une étude de cas sur la France, en comparant les résultats obtenus pour un Lycée GT et un Lycée Pro par ex.).
- Variables d'intérêt (technologies et leurs utilisations, performances éducatives) :
 - Technologies :
 - * ST326Q01JA : digital_resources_usage_for_learning_at_school_by_day
 - * ST326Q02JA : digital_resources_usage_for_learning_outside_school_by_day
 - * ST326Q03JA : digital_resources_usage_for_learning_on_weekends
 - * ST326Q04JA : digital_resources_usage_for_leisure_at_school_by_day
 - * ST326Q05JA : digital_resources_usage_for_leisure_outside_school_by_day
 - * ST326Q06JA -> digital_resources_usage_for_leisure_on_weekends
 - * ST253Q01JA : nb_digital_devices_at_home
 - * IC174Q10JA : digital_games_usage_for_learning

– Performances éducatives :

- * REPEAT : repeated_a_year
- * PV1MATH : pv_math
- * PV1READ : pv_reading_comprehension
- * PV1SCIE : pv_science

Faisons alors un élagage du dataframe avec ces nouvelles variables :

```
responses <- responses_raw |>
  select(
    country = CNT,
    birth_year = ST003D03T,
    genre = ST004D01T,
    index_highest_parental_education = PAREDINT,
    index_highest_parental_occupation_status = HISEI,
    index_socioeconomic_status = ESCS,
    computer_for_work_available = ST250Q02JA,
    educational_apps_available = ST250Q03JA,
    internet_access_available = ST250Q05JA,
    response_medium = ADMINMODE,
    book_reading_for_school = ST256Q10JA,
    region_and_schools = STRATUM,

    digital_resources_usage_for_learning_at_school_by_day = ST326Q01JA,
    digital_resources_usage_for_learning_outside_school_by_day = ST326Q02JA,
    digital_resources_usage_for_learning_on_weekends = ST326Q03JA,
    digital_resources_usage_for_leisure_at_school_by_day = ST326Q04JA,
    digital_resources_usage_for_leisure_outside_school_by_day = ST326Q05JA,
    digital_resources_usage_for_leisure_on_weekends = ST326Q06JA,
    nb_digital_devices_at_home = ST253Q01JA,
    digital_games_usage_for_learning = IC174Q10JA,

    repeated_a_year = REPEAT,
    pv_math = PV1MATH,
    pv_reading_comprehension = PV1READ,
    pv_science = PV1SCIE
  )
```

Partie II: Ebauche de plan

Partie préliminaire : accès aux technologies - impact des variables socio-économiques et géographique sur cet aspect.

Partie 1.

A. L'utilisation des technologies sur le performances scolaires a un impact positif

B. Pleins de facteurs qui influencent néanmoins cet impact.

i. l'Age/le niveau scolaire

ii. l'utilisation qui est faite des technologies

Partie 2. Un effet de seuil ?

A. Faire variable qui est un score de performance scolaire (réussir a quantifier la performance scolaire avec plusieurs variables).

B. Pouvoir tracer une courbe des performances scolaires en fonction de la fréquence d'utilisation d'outils numériques. ==> Quand on conditionne ça par rapport à d'autres variables en fonction de l'age, du niveau scolaire, ... les courbes ont des tendances différentes.